

특집논문 (Special Paper)

방송공학회논문지 제24권 제6호, 2019년 11월 (JBE Vol. 24, No. 6, November 2019)

<https://doi.org/10.5909/JBE.2019.24.6.1013>

ISSN 2287-9137 (Online) ISSN 1226-7953 (Print)

시청 시간대 정보를 활용한 LSTM 기반 IPTV 콘텐츠 추천

표 신 지^{a)†}, 정 진 환^{a)}, 송 인 준^{a)}

LSTM-based IPTV Content Recommendation using Watching Time Information

Shinjee Pyo^{a)†}, Jin-Hwan Jeong^{a)}, and Injun Song^{a)}

요 약

수많은 채널과 VoD 콘텐츠, 웹 콘텐츠들이 존재하는 콘텐츠 소비 환경에서의 추천은 이제 선택이 아닌 필수가 되었다. 현재 OTT 서비스나 IPTV 서비스에서도 많은 사람들이 선호하는 콘텐츠를 추천하거나 사용자가 시청한 콘텐츠와 유사한 콘텐츠들을 추천하는 등, 다양한 종류의 추천 서비스들이 제공되고 있다. 하지만 TV, IPTV와 같이 대체로 한 가구당 하나의 가입정보와 하나의 TV, 셋탑박스를 공유하는 TV를 통한 콘텐츠 시청환경의 경우, 하나의 가입정보에 1명 이상의 사용 이력이 쌓여 특정 사용자에게 대한 추천을 제공하기에 어려움이 존재한다. 본 논문에서는 이러한 문제를 해결하기 위해 가족의 개념을 {사용자, 시간}으로 해석하여, 기존의 {사용자, 콘텐츠}로 정의하는 추천 관계를 {사용자, 시간, 콘텐츠}으로 확장하고 이를 딥러닝 기반으로 해결하는 방법을 제안한다. 제안한 방법을 통해 추천 성능을 정성적 정량적으로 평가하였으며, 기존의 시간대를 고려하지 않은 방법과 비교하여 추천 정확도가 향상됨을 확인할 수 있었다.

Abstract

In content consumption environment with various live TV channels, VoD contents and web contents, recommendation service is now a necessity, not an option. Currently, various kinds of recommendation services are provided in the OTT service or the IPTV service, such as recommending popular contents or recommending related contents which similar to the content watched by the user. However, in the case of a content viewing environment through TV or IPTV which shares one TV and a TV set-top box, it is difficult to recommend proper content to a specific user because one or more usage histories are accumulated in one subscription information. To solve this problem, this paper interprets the concept of family as {user, time}, extends the existing recommendation relationship defined as {user, content} to {user, time, content} and proposes a method based on deep learning algorithm. Through the proposed method, we evaluate the recommendation performance qualitatively and quantitatively, and verify that our proposed model is improved in recommendation accuracy compared with the conventional method.

Keyword : Content recommendation, Context-aware, Deep learning, LSTM

a) SK텔레콤(SK Telecom)

† Corresponding Author : 표신지(Shinjee Pyo)

E-mail: sj.pyo@sk.com

Tel: +82-2-6100-2959

ORCID: <https://orcid.org/0000-0003-2702-905X>

· Manuscript received September 26, 2019; Revised October 29, 2019; Accepted October 29, 2019.

Copyright © 2016 Korean Institute of Broadcast and Media Engineers. All rights reserved.

“This is an Open-Access article distributed under the terms of the Creative Commons BY-NC-ND (<http://creativecommons.org/licenses/by-nc-nd/3.0>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited and not altered.”

1. 서론

다양한 콘텐츠들이 제공되는 콘텐츠 소비환경에서의 추천은 사용자로 하여금 콘텐츠를 고르고 선별하는데 드는 노력을 줄여주고 효율적으로 콘텐츠를 소비할 수 있도록 돕는다. Netflix나 YouTube에서의 추천은 사용자가 좋아할 만한 더 다양한 콘텐츠들을 소비할 수 있도록 복잡한 추천 알고리즘을 설계, 사용자에게 질 높은 추천 서비스를 제공하고 있다. 하지만 이러한 OTT 서비스의 경우와 달리, TV를 통한 콘텐츠 시청 서비스의 경우, 특정 사용자에 대한 구분이 어렵다는 제약이 있다. 즉, TV를 시청하는 사용자가 가족구성원 중 어떤 구성원인지 부가적인 인식과정이 있지 않고서는 식별해 낼 수 없다는 물리적 제약이 존재한다. Netflix의 경우에는, TV를 통한 시청환경을 고려하여 가입자 정보 내에서 여러 프로파일을 생성, 관리하는 명시적인 방식으로 이러한 문제를 해결하고자 하였다. Netflix 서비스를 이용할 때, 가입자 한명으로 복수의 프로파일을 생성할 수 있고, 서비스 이용 시 여러 프로파일 중 자신이 생성한 프로파일을 선택하여 이용할 수 있도록 하였다. 이

러한 프로파일을 통한 서비스의 경우, 사용자에게 부가적인 입력을 요구하게 되어 사용자에게 번거로운 요소로 작용할 수 있다. 따라서 본 논문에서는 사용자의 부가적인 입력 없이도 사용이력 분석을 통하여 특정 시간대에 따른 추천을 제공함으로써 가구 당 여러 사용자가 있을 때, 해당 사용자의 주 TV시청 시간대에 적합한 추천을 제공하는 추천 모델을 제안한다. 제안하는 모델에서는 TV를 시청한 시간대가 특정 사용자와 연관성이 있다는 데이터 분석 결과를 기반으로 한다. 소비 취향은 어느 단위 기간의 반복적인 습관이며, 사람 역시 어떤 시간 단위로 반복되는 성향이 있기에 결국 특정 시간대의 사용자는 다음 반복되는 특정 시간대에 동일인을 가능성이 높다고 추정할 수 있다. 본 논문에서는 이러한 가능성을 데이터 분석을 통해 확인하고 이를 정의하는 모델을 제안하고자 한다. 제안 모델은 딥러닝 모델 중 시간 순서를 고려한 RNN(Recurrent Neural Network) 중 하나인 LSTM(Long-short term memory)^[1]을 기반으로 설계하였으며, 자세한 모델 구성은 3절에서 설명하도록 한다. 또한 추천을 위한 다양한 딥러닝 모델 및 TV시청환경에 적합한 추천 관련 연구에 대한 내용은 2절에서 자세히

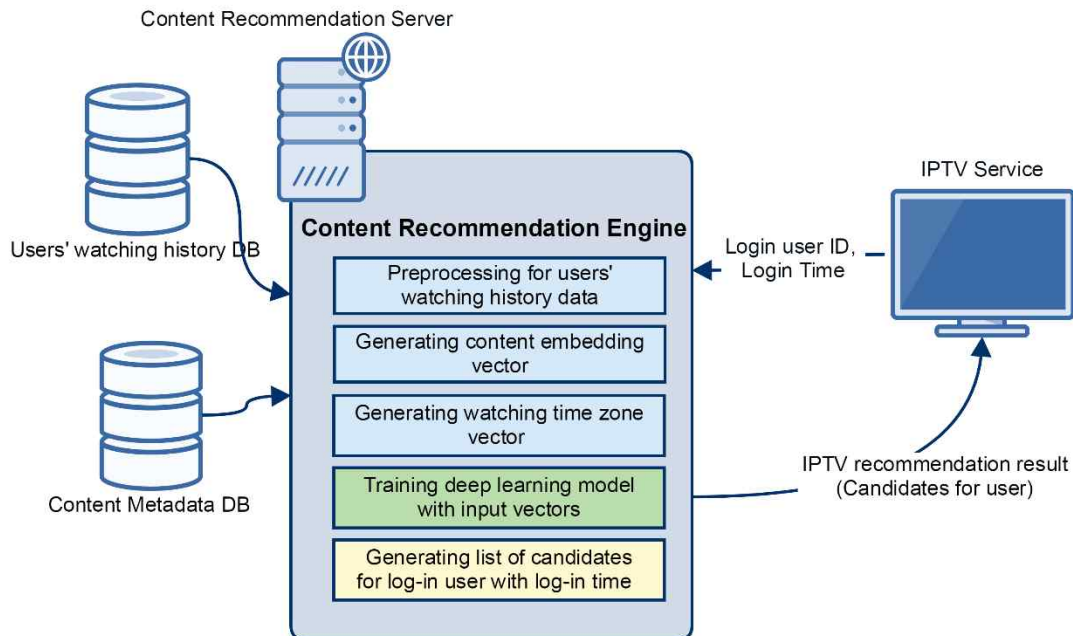


그림 1. IPTV 콘텐츠 추천 시스템 개념도

Fig. 1. IPTV content recommendation system framework

설명하도록 한다.

그림 1은 제안하는 IPTV 콘텐츠 추천시스템 개념도이다. 콘텐츠 추천 엔진은 사용자의 시청이력 데이터가 수집되는 DB, 콘텐츠 메타데이터DB와 연결되어 사용자 시청이력 데이터 전처리, 모델 입력생성을 위한 벡터 임베딩과정을 거쳐 제안한 모델을 학습하며, 학습된 모델을 기반으로 사용자 별 추천 콘텐츠 목록을 생성하게 된다. IPTV 사용자가 셋탑박스 전원을 키고 IPTV 콘텐츠 서비스를 실행하게 되면, 사용자(셋탑박스ID)와 서비스 실행 시각이 콘텐츠 추천엔진에 전송되고, 해당 사용자와 실행시각에 맞는 콘텐츠 추천 목록이 사용자의 IPTV 추천 서비스로 노출된다.

II. 관련 연구

추천 시스템에 대한 연구는 전자상거래의 발달과 함께 그 필요성과 중요성이 대두되면서부터 보다 활발하게 진행되어 왔으며, 최근 빅데이터와 딥러닝 기술의 폭발적 발전으로 다양한 추천 알고리즘과 어플리케이션, 실제 서비스 적용사례에 대한 논문도 대거 발표되고 있다. 본 논문에서는 추천 시스템 중 TV 추천 시스템에 대한 연구와 딥러닝 기반의 콘텐츠 추천 모델에 대한 관련 연구를 소개한다.

1. TV 추천 시스템 관련 연구

[2]에서는 시청 시간 패턴을 사용자의 시청 선호도 계산에 활용하여 TV 프로그램을 추천하는 추천 시스템을 제안하였다. 사용자별 전체 콘텐츠 선호도 계산을 위해 SVD(Singular value decomposition)를 활용하였으며, 부가적으로 시청비율 기반 선호도 및 최근 시청 이력에 가중치를 주도록 최종 선호도 값을 계산, 추천 정확도를 향상시켰다. 제안모델의 경우, 사용자가 TV프로그램을 전체 방영시간 대비 얼마만큼의 비율로 시청했는지를 고려하여 각 TV프로그램의 선호도를 정교하게 계산하였지만, 실제 해당 TV 프로그램을 시청한 시간대를 고려하지는 않았다. [3]에서는 방송 콘텐츠의 특성인 주기성, 실시간성을 고려하여 특성벡터를 고안하였으며, 이를 decision tree에 활용, 추천에 적합한 rule을 생성하였다. 이러한 decision tree를 이용한

rule-based방식의 경우 feature들이 복잡해지고, 실험 데이터가 많아질 경우 정확성과 효율성 측면에서 적합하지 않다는 제약이 있다. [4]에서는 topic modeling 기법을 활용하여 TV 시청사용자의 유사 그룹을 생성하고, 각 사용자의 유사 그룹 간의 관계를 기반으로 사용자별 콘텐츠를 추천하는 알고리즘을 제안하였다. 또한 시간의 흐름에 따라 변화하는 사용자 선호도를 고려하여 유사 사용자 그룹을 동적으로 생성할 수 있는 모델을 제안하여 추천 정확도를 향상시켰다. 하지만 [4]의 제안 모델의 경우에도 시청한 시간대를 고려하고 있지는 않았다. 이렇듯 TV 콘텐츠 추천 관련 연구에서는 다양한 기법을 활용하여 TV 콘텐츠를 추천하는 방법을 제안하였으나, 앞서 제기했던 TV시청 사용자에게 대한 식별문제를 고려한 방법은 아니었다.

2. 딥러닝 기반 추천 시스템 관련 연구

[5]는 딥러닝 기법을 활용한 다양한 추천 알고리즘에 대해 정리한 논문이다. 딥러닝 기반 알고리즘들이 이미지 처리 및 분석, 자연어 처리 분야 등에서 획기적인 성능 향상을 보임으로써 추천 분야에서도 딥러닝 기법을 활발히 적용하고 있으며 그 성능이 기존의 MF(matrix factorization)기반의 선호도 예측방법, generative process 기반의 확률적인 접근 방법 보다 월등한 성능을 나타내게 되었다. [5]에서 언급한 딥러닝 기반의 추천 시스템으로는 auto-encoder를 기반으로 한 long-tail 웹 서비스 추천 알고리즘[6], 사용자의 순차적인 이력을 활용한 RNN기반의 추천 알고리즘[7] 등 다양한 추천 알고리즘을 딥러닝 기법에 따라 분류하였다. Youtube 콘텐츠 추천 알고리즘이라고 잘 알려진 [8]에서는 DNN(Deep Neural Network) 기반의 콘텐츠 추천 알고리즘을 소개하였다. 사용자가 시청한 각각의 콘텐츠들을 벡터로 표현한 뒤, 사용자별 시청 콘텐츠 벡터들을 평균 벡터를 모델의 기본 입력으로 활용하였으며, 이외에도 사용자가 검색한 검색이력, 사용자의 위치정보를 벡터화 하여 입력으로 활용하였다. 하지만 [8]에서도 사용자의 순차적인 시청이력 및 시청 시간대에 대해 고려하지 않았다. [9]에서는 RNN기반의 session-based 추천 시스템을 제안하였다. [9]에서는 RNN모델 중 하나인 GRU(Gated Recurrent Unit)^[10]를 활용하여 인터넷 환경에서의 한 세션내 사용자




그림 2. 시청 콘텐츠의 vector embedding

Fig. 2. Vector embedding of watching content

이력을 기반으로 이후에 사용자가 선택할 콘텐츠를 추천하는 모델을 제안하였다. 또한 [11]에서는 LSTM모델을 활용하여 사용자의 이전까지의 영화 시청이력을 바탕으로 사용자가 다음에 볼 만한 영화를 예측하는 모델을 제안하였다. 이러한 딥러닝 기반의 다양한 추천 모델들이 연구되었지만 TV 시청환경에서 시청 시간대를 고려하여 TV 사용자에게 적합한 추천을 제공하는 방법은 아니었다. 따라서 본 논문에서는 이러한 제한점을 극복하는 LSTM기반의 추천 모델을 제안하고자 한다.

III. 제안 모델

1. 모델 입력 데이터 구성

제안 모델은 사용자의 IPTV 시청이력을 시퀀스로 표현하여 모델의 입력으로 활용하였다. 시퀀스를 이루는 요소로는 시청한 콘텐츠에 대한 콘텐츠 식별자, 해당 콘텐츠를

시청한 시간대 정보, 해당 콘텐츠의 방영시간 대비 시청시간 비율, 세 가지로 구성하였다. 수식으로 표현하면 다음과 같다.

$$Seq_{user1} = \langle s_1(CID_1, T_{CID_1}, R_{CID_1}), s_2(CID_2, T_{CID_2}, R_{CID_2}), \dots, s_n(CID_n, T_{CID_n}, R_{CID_n}) \rangle$$

Seq_{user1} 은 사용자 $user1$ 의 시청 시퀀스를 뜻하며, si 은 시퀀스 중 i 번째 요소를 나타낸다. 각각의 si 들은 시청 콘텐츠의 콘텐츠 식별자 CID_i , 시청 콘텐츠 CID_i 를 시청종료한 시간 정보인 T_{CID_i} , 그리고 해당 콘텐츠의 방영시간대비 시청시간 비율정보인 R_{CID_i} 로 구성하였으며, 시퀀스는 콘텐츠 시청 시간 순서대로 정렬하였다. 제안 모델은 추천을 제공하기 위해 사용자로부터 추가적인 입력을 받지 않고, 사용자 시청 이력 정보를 사용자별로 분류된 시퀀스들로 분류, 정제하여 모델의 입력으로 사용하였다. 시퀀스의 구성 요소 중 콘텐츠 식별자에 대해서는 word2vec^[12] 기법을 활

표 1. 콘텐츠 embedding vector를 활용한 유사 콘텐츠 예시

Table 1. Examples of similar contents based on content embedding vector

Seed content	Ant-Man and the Wasp (SF)	Pretty Woman (Melodrama)
List of similar contents based on vector similarity	1. Black Panther (0.965) 2. Thor: Ragnarok (0.964) 3. Captain America: Civil War (0.956) 4. Avengers: Infinity War (0.953) 5. DEADPOOL 2 (0.950) 6. Avengers: Age of Ultron (0.937) 7. Ant-Man (0.932) 8. Avengers: End Game (0.931) 9. Justice League (0.928) 10. Spider-Man (0.927)	1. Lover's Concerto (0.927) 2. Love and Other Disasters (0.921) 3. Memories of Matsuko (0.917) 4. Birds Without Names (0.914) 5. Ori Ume (0.913) 6. Lady Macbeth (0.911) 7. The Table (0.911) 8. Radio Dayz (2008) (0.909) 9. Petty Romance (0.902) 10. Adrift (0.899)

용해 각각의 콘텐츠 식별자를 벡터화 함에 따라 함께 자주 시청된 콘텐츠의 경우 유사한 벡터 값을 갖는다. 표1은 word2vec 수행한 후, 유사 콘텐츠 목록과 각각의 유사도 값의 예시이다. 표1에서와 같이 “엔트맨과 와스프”라는 SF 영화와 유사한 콘텐츠로 추천된 목록에는 “블랙팬서”, “토르”, “캡틴 아메리카”와 같은 마블 시리즈 영화들이 상위에 포함되어 있다. 즉, “엔트맨과 와스프” 영화를 시청한 사용자들이 이와 유사한 영화들을 함께 시청하였음을 뜻한다. 마찬가지로 멜로영화인 “귀여운 여인”과 유사한 콘텐츠로는 동일 장르인 멜로 영화들이 주로 나타나고 있다.

본 예시의 경우, 콘텐츠간 유사도가 정성적으로도 유사하게 나타난 것을 알 수 있다. 하지만 이렇게 사용자의 시청 시퀀스에 따라 각 콘텐츠의 입력 벡터를 생성한 경우, 전혀 유사한 장르의 콘텐츠가 아님에도 유사한 입력 벡터가 생성된 경우도 존재하였다. 그 이유는, 서론에도 이야기했듯이 하나의 섯답박스로 콘텐츠를 시청하는 실제 사용자는 가구 구성원의 수에 따라 여러 명이 될 수 있고 결국 상이한 콘텐츠 종류가 연속된 시청 시퀀스를 구성하는 경우가 OTT 서비스에 비해 다수 있기 때문이다. 예를 들어 가구원 중 성인과 유아가 함께 있는 경우, 가구원 중 성인이 최근 개봉한 공포 영화를 시청 한 후 가구원 중 유아가 유아용 콘텐츠를 시청한 경우, 또는 가구원 중 성인이 드라마를 시청한 후 가구원 중 유아가 만화 콘텐츠를 시청한 경우, 공포 영화-유아용 콘텐츠, 드라마-만화 콘텐츠가 유사한 콘텐츠 입력 벡터 값을 갖게 되는 문제점이 있다. 이를 해결하기 위해 각 콘텐츠의 벡터와 9개 종류의 장르 정보를 나타내는 One-Hot Encoding 벡터를 결합하여 새로운 콘텐츠 입력 벡터를 생성하였다. 장르 정보는 각 콘텐츠의 메타데이터 정보를 통해 얻을 수 있었으며, 드라마, 예능, 영화, 스포츠, 시사교양, 다큐, 키즈, 애니, 교육 등의 장르로 나누었다. 이러한 벡터로 모델을 학습하게 될 경우, 유사 시청 패턴을 갖는 콘텐츠들끼리 유사한 입력 벡터 값을 갖음과 동시에 콘텐츠 자체적인 정보를 고려하여 정성적 정량적으로 모델 성능을 향상시킬 수 있었다. 그림 2은 시사 교양 프로그램인 “그것이 알고싶다”의 콘텐츠 임베딩 벡터를 표현한 예시이다. 앞부분의 16차원 벡터는 “그것이 알고싶다”의 word2vec 수행 결과 벡터이고, 뒷부분의 9차원 벡터는 “그것이 알고싶다”

의 장르인 “시사교양”장르를 One-Hot Encoding 으로 표현한 벡터로서 “그것이 알고싶다”라는 콘텐츠를 총 25차원의 벡터로 표현하여 모델의 입력으로 활용하였다.

각 콘텐츠 식별자에 대한 벡터 값을 생성 한 후, 시퀀스를 구성하는 두 번째 요소인 시간대 정보에 대하여 다음과 같이 6차원의 벡터로 표현한다. 제안 모델에서는 시청 시간정보에 대하여 사용자의 시청 행태가 일반적으로 일주일 단위로 반복되는 특성을 고려하여 사용자의 시청 이력 중 시청 시간 정보를 그림 3과 같이 표현하도록 하였다.

시간 정보를 이렇게 표현하게 함으로써 연속적인 시간 정보를 주기성을 가진 벡터 값으로 표현할 수 있도록 하였으며, 미래 시점에 대한 예측도 가능하도록 하였다.




그림 3. 시청 시간의 vector embedding
Fig. 3. Vector embedding of watching time

시퀀스를 구성하는 세번째 요소인 각 콘텐츠 별 시청 비율은 사용자 별 추천 목록 구성 시에 활용하였다. 일정 임계값 이상인 시청 비율을 갖는 콘텐츠에 대해서는 사용자가 이미 많이 시청했다고 여겨 추천 목록에서 제거하여 추천 목록에 보다 더 다양한 콘텐츠들이 포함될 수 있도록 하였다.

2. 모델 구조

제안 모델은 RNN 중 하나인 LSTM 모델을 기반으로 하며 모델 구조는 그림 4과 같다. 모델의 입력으로 가입자 별 시청 콘텐츠를 시간 순서를 갖는 시퀀스로 추출, 시퀀스 길이가 4인 시청 시퀀스를 입력으로 사용하였다. 각 시퀀스를 구성하는 요소로는 시청한 콘텐츠를 표현하는 벡터이며, 부가적으로 해당 시퀀스의 마지막 시청 시간대 정보인 6차원 벡터와 정답 label로 들어가는 시청 콘텐츠의 시청 시간대

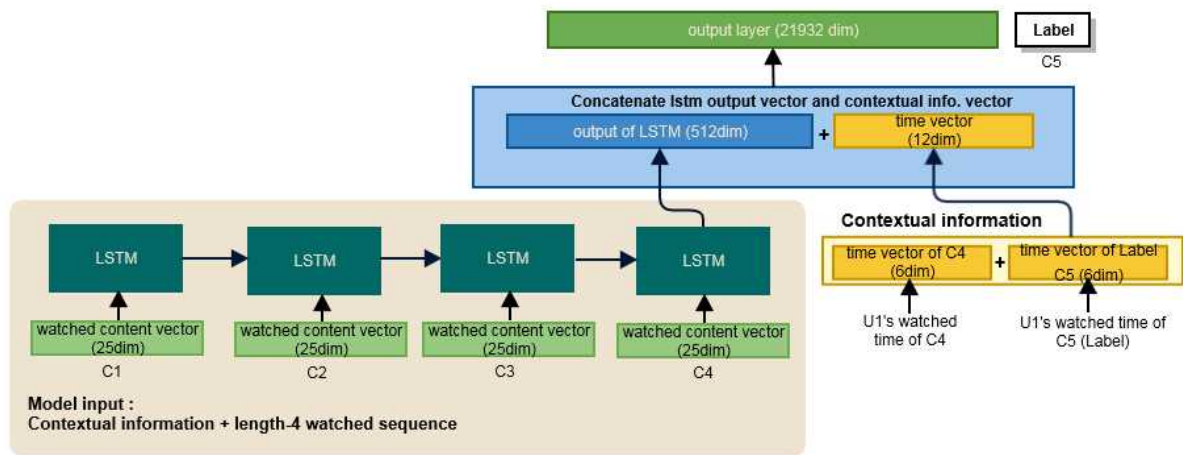


그림 4. 제안 모델

Fig. 4. Proposed model

정보인 6차원 벡터를 concatenate하여 사용하였다. 마지막 시청 시간대 정보와 미래에 예측할 시간대 정보는 LSTM layer의 output 값과 concatenate하여 최종 output layer의 입력으로 사용하였으며, 최종 output layer는 softmax로 전체 2만여개의 콘텐츠 중 특정 콘텐츠 1개를 맞추도록 모델을 학습하였다. 제안 모델에서 특정 시간대에 따른 콘텐츠 label값을 학습함에 따라 사용자 별 시청 시간대에 따른 시청 콘텐츠 특성을 반영할 수 있는 모델로 학습되며, 사용자 별 추천 목록을 제공하기 위해 inference를 수행할 때에도 특정 시간대에 대한 추천 목록을 생성할 수 있어, 시간대에 따른 다양한 추천을 제공할 수 있다는 장점이 있다.

IV. 실험 결과

1. Data set

제안모델의 성능을 검증하기 위해 실험에 활용한 데이터는 표 2와 같다. 실험 데이터의 종류는 셋탑박스 id별 IPTV 시청이력 데이터이며, 기간은 수집 기간은 4개월, 총 활용한 셋탑박스 id는 약 190만개, 시청 이력에 포함된 콘텐츠 종류 개수(여러 회차를 갖는 TV프로그램의 경우, 하나의 콘텐츠로 여김)는 29284개이다. 또한 모델 학습과 테스트용 데이터로 전체 데이터를 나누었는데, 전체 사용자를 기준으로 70%의 사용자의 시청이력을 학습을 위해 사용하였고, 30%의 사용자의 시청이력을 성능 검증을 위해 사용하

표 2. 실험 데이터

Table 2. Data set for experiment

Data type	Watching history of IPTV set-top box id (set-top box id: unidentifiability data)
Period	2019.05~08 (4 months)
Number of set-top box id	1,939,468
Number of distinct watching contents	29,284
Number of total watching histories	36,195,773
Average length of sequence for set-top box id	18.66
Training set	Watching histories of 70% of total set-top box id
Test set	Watching histories of 30% of total set-top box id

표 3. 비교 실험 설계

Table 3. Comparative experiment

	LSTM+time label+genre (LSTM based model with considering content watching histories, watching time and content genre) Proposed model
Comparison1	LSTM+time label (LSTM based model with considering content watching histories and watching time)
Comparison2	LSTM+genre (LSTM based model with considering content watching histories and content genre)
Comparison3	LSTM(LSTM based model with considering content watching histories)

였다. 셋탑박스 별 시청이력 데이터 이외에도 시청한 콘텐츠 각각에 대한 메타데이터도 함께 활용하였으며, 메타데이터에는 각 콘텐츠에 대한 제목, 콘텐츠 식별자, 콘텐츠 장르가 포함되어 있다.

2. 실험 설계

제안 모델과 기존 모델과의 성능 비교를 위해 표3과 같이 실험을 설계하였다.

가장 기본적인 LSTM 모델(비교실험3)의 경우, 모델 입력으로 각 콘텐츠에 대한 w2v embedding vector 만을 사용하여 학습하였으며, 기본 LSTM 모델에 시청 시간대 정보를 추가한 모델(비교실험1), 기본 LSTM 모델에 콘텐츠 별 장르 정보를 추가한 모델(비교실험2)로 비교 실험군을 구성하였다.

3. 실험 결과

3.1 정량적 결과

먼저 제안 모델과 비교 모델의 성능을 정량적 지표로 비교하였다. 정량적 지표로는 training loss, training accuracy와 mAP(mean average precision)을 사용하였다. mAP은 사용자 별 추천 목록의 추천 순위도 함께 고려하는 성능 지표로서, 상위 순위의 추천 콘텐츠를 실제 사용자가 시청했을 때, 하위 순위의 추천 콘텐츠를 실제 사용자가 시청했을 때보다 더 높은 mAP값을 갖도록 설계한 지표이다. mAP의 수식은 다음과 같다.

$$mAP = \frac{1}{M} \sum_{i=1}^M \frac{1}{|D_i|} \sum_{j=1}^Q \frac{\sum_{k=1}^j rel_{D_i}(R_i(k))}{j},$$

$$rel_D(r) = \begin{cases} 1, & \text{if } r \in D \\ 0, & \text{otherwise} \end{cases}$$

수식에서 M은 전체 추천 제공자(사용자)의 수, Di는 i번째 사용자의 ground truth, Q는 사용자에게 제공되는 추천 콘텐츠 개수, Ri(k)는 i번째 사용자에게 추천된 k번째 콘텐츠를 뜻한다. 각 모델 별 정량적 지표를 비교하기 위해서 모델 학습에 사용한 공통의 모델 파라미터는 표4와 같다. 모델의 입력과 구조이외에 다음의 모델 파라미터는 모든 모델에서 동일하게 사용되었다.

표 4. 모델 파라미터

Table 4. Model parameters

Model parameter	Value
Sequence length	4
Number of LSTM layer	1
Learning rate	5e-05
Hidden dim of LSTM cell	100
Output dim of LSTM cell	200
Label sliding	5
Min cut watching time	10 (except the contents which watched less 10 times)
Batch size	1,024
Epoch	5
Number of training instance	71,639,345
Number of class	21,932

표 4의 모델 파라미터로 모델을 학습하고, 추론하여 추천 목록을 생성, mAP 지표를 계산하였다. 제안 모델의 모델 학습 시, 정답 값으로 사용되는 label 콘텐츠의 시청 시간대가 모델 입력으로 함께 들어가 추천 목록을 생성할 때, 특정 시간대에 시청할 확률이 높은 콘텐츠들을 추천하게 된다. 따라서 공정한 비교를 위해, 모든 실험에서는 셋탑박스 별 추천목록과 비교할 ground truth 값으로 입력 시청 시퀀스(예: C1-C2-C3-C4) 이후에 시청한 1개의 콘텐츠만을(예: C5) ground truth로 사용하였다. mAP 계산에 사용되는 각

셋답박스 별 추천 콘텐츠 개수는 50으로 하였으며, 추천을 제공한 셋답박스 수는 학습에 사용되지 않은 임의로 선별한 200704명(최소 시청 시퀀스 길이가 5이상)으로 모든 실험에서 동일하게 사용하였다.

표 5. 정량적 성능 비교

Table 5. Comparison of quantitative performance

	mAP (%)	Training accuracy(%)	Training loss
Proposed model (+time label + genre)	25.7445	12.9545	5.899
Comparison 1 (+time label)	25.6557	12.9059	5.906
Comparison 2 (+genre)	25.5659	12.8581	5.944
Comparison 3 (none)	25.3671	12.7441	5.952

표 5에서와 같이 제안 모델의 mAP값이 다른 모델의 비해 향상되었음을 확인하였으며, 동일한 학습횟수에도 training accuracy가 향상, training loss가 감소하였다. 또한 비교모델1(time label만 추가)과 비교 모델2(콘텐츠 벡터에 장르 정보만 추가)에서 비교모델 1의 성능이 비교모델2의 성능보다 더 좋은 것을 알 수 있었는데, 이는 시청 시간대 정보

가 장르 정보보다 추천 성능 향상에 더 중요한 feature임을 뜻한다. 비교모델2와 비교모델3과의 비교에서도 단순히 시청 이력만을 사용한 경우보다 콘텐츠 w2v 벡터에 장르 벡터를 추가하여 학습, 추천한 결과가 좀더 나은 성능을 보임을 확인할 수 있었다.

3.2 정성적 결과

제안 모델과 비교 모델의 추론 결과로 생성된 셋답박스 별 추천 콘텐츠 목록을 정성적으로 평가할 수 있도록 각 콘텐츠 식별자를 콘텐츠 제목으로 바꾸어 확인해보았다. 먼저 제안 모델의 경우, 추천 목록을 제공할 미래 시간대 정보를 추론할 때에 입력으로 사용하기 때문에, 다양한 시간대 정보에 따라 어떻게 추천 목록이 달라지는지도 부가적으로 확인할 수 있었다. 즉, 동일한 시청 시퀀스로 추론을 수행했더라도, 서로 다른 예측 시간대정보에 따라 추천 목록에 차이가 있었다.

표 6에서와 같이 입력 시퀀스의 마지막 콘텐츠인 예능 콘텐츠(개그 콘서트)와 관련된 콘텐츠들이 추천 목록 상위에 포함되어 있었으며, time label에 따라 추천 목록의 구성이 상당 부분 달라진 것을 확인할 수 있었다. 또한 time

표 6. 시간대 label에 따른 추천 목록 비교

Table 6. Comparison of recommended lists for different time labels

Input sequence (1-2-3-4) : Lefty wife(Drama) - Lefty wife(Drama) - Doctor Strange(Movie) - Gag Concert(Ent.)	
Time label = Weekdays dawn	Time label = Weekend morning
1 Ent. 0.97799 Gag Concert	1 Ent. 0.97918 Gag Concert
2 Ent. 0.96599 Running	2 Ent. 0.97587 Happy Sunday - Superman
3 Ent. 0.96276 Happy Sunday - Superman	3 Ent. 0.96692 Running mans
4 Ent. 0.92449 TV animal farm	4 Ent. 0.94587 TV animal farm
5 Ent. 0.90920 Single life	5 Ent. 0.91135 Single life
6 News 0.89778 Real situation	6 Drama 0.89617 Fiery priest
7 Drama 0.89156 Fiery priest	7 News 0.89579 Captured moments! Unbelievable
8 Ent. 0.88364 Knowing bros	8 Ent. 0.88762
9 Ent. 0.87712 Talk show-Hello	9 News 0.87055 Real situation
10 News 0.87368 I am a natural man	10 Kids 0.84224 Hello Jadool!
11 News 0.86369 Captured moments! Unbelievable!	11 Ent. 0.84006 Mystery TV Surprise
12 Drama 0.86283 Forensic	12 Drama 0.83898 My only one
13 Drama 0.86265 My only one	13 Ent. 0.82640 Comedy Big League
14 Ent. 0.85460 Miss trot	14 Ent. 0.80282 Great escape
15 Ent. 0.85050 Comedy Big League	15 Ent. 0.79382 Miss trot
16 Ent. 0.83733 Mystery TV Surprise	16 Ent. 0.79260 Talk show-Hello
17 Ent. 0.83596 Paik Jongwon's Alley restaurant	17 Ani. 0.76815 NEW Baby dinosaur Dolly
18 Drama 0.80832 Lefty wife	18 News 0.75734 Unanswered questions
19 Ent. 0.80175 Ugly my son	19 News 0.75472 I am a natural man
20 Drama 0.79423 Dr. Prisoner	20 Ent. 0.73675 Great escape 2




그림 5. 시청 시간대별 콘텐츠 장르 분포

Fig. 5. Distributions of content genres for different watching time zone

label에 따른 추천 목록은 각 시간대별 대체적인 시청 특성을 반영하는 것으로 나타났다. 각 시간대 별 대체적인 시청 특성은 전체 시청 이력을 모델에서 활용한 총 8가지 종류의 시간대로 나눈 뒤, 각 시간대에서 많이 시청된 Top 100개

콘텐츠들의 장르를 계수한 것으로 파악할 수 있었다.

그림 5에서와 같이 드라마 장르의 경우에는 전체 시간대에서 모두 시청이 많이 되었으며 특히 주중 새벽에 가장 많이 시청되었다. 키즈 장르의 경우에는 주중 새벽, 주말

표 7. 제안 모델과 비교모델3의 추천 목록 비교

Table 7. Comparison of recommended lists for proposed model and Comparison3 model

Input sequence (1-2-3-4) : M Countdown(Ent.) - You quiz on the block(Ent.) - You quiz on the block (Ent.) - Nine(Drama)	
Candidates list of proposed model	Candidates list of Comparison3
1 Ent. 0.84492 Kang's Kitchen 2	1 Drama 0.91134 Search WWW
2 Drama 0.78811 Search WWW	2 Drama 0.88706 Forest of Secret
3 Drama 0.76528 Forest of Secret	3 Ent. 0.87571 Kang's Kitchen 2
4 Drama 0.73366 Voice 3	4 Drama 0.84717 My Mister
5 Ent. 0.73047 Kang's Kitchen 3	5 Drama 0.84653 Signal
6 Drama 0.71539 Hotel Del Luna	6 Drama 0.84180 Hotel Del Luna
7 Drama 0.69871 Arthdal Chronicles	7 Drama 0.83983 Forensic season2
8 Ent. 0.68425 Single life	8 Drama 0.83432 Nine
9 Drama 0.66376 WATCHER	9 Ent. 0.81190 Single life
10 Drama 0.66198 Nine	10 Drama 0.80115 Misaeng
11 Ent. 0.65244 Produce X 101	11 Ent. 0.79896 Kang's Kitchen 3
12 Drama 0.62436 Signal	12 Drama 0.79253 Prison play book
13 News 0.56192 Unanswered questions	13 Drama 0.78714 Arthdal Chronicles
14 Drama 0.53873 Forensic season2	14 Drama 0.77357 Voice 3
15 Drama 0.53825 Prison play book	15 Drama 0.76847 WATCHER
16 Ent. 0.53145 4 Wheeled restaurant- USA	16 Drama 0.76753 60days, Designated Survivor
17 Drama 0.52377 My Mister	17 Drama 0.73846 Confession
18 Drama 0.49558 One spring night	18 Ent. 0.73461 Produce X 101
19 Drama 0.49124 Aide	19 Drama 0.73368 100days My prince
20 Ent. 0.48389 Amazing Saturday	20 Drama 0.71321 One spring night
Average Precision : 1	Average Precision : 0.33
Time label : Weekend dawn	
Ground truth : Kang's Kitchen 2 (Ent.)	

새벽을 제외하고 다른 시간대 모두 많이 시청되었으며 특히 주말 오전에 가장 많이 시청되었다. 예능 장르의 경우에는 주말 새벽에 가장 많이 시청되었으며, 시사교양 장르도 마찬가지로 주말 새벽에 가장 많이 시청되었다. 이러한 시간대 별 시청 특성이 **time label**에 따른 추천 목록 구성에도 영향을 끼쳐 표 6에서의 “**time label=Weekend morning**(주말 오전)”의 경우, 키즈, 애니 장르 콘텐츠와 같이 어린이용 콘텐츠가 추천 목록에 포함된 것을 확인할 수 있었으며 주중 새벽의 추천 목록의 경우에는 드라마 장르의 콘텐츠들이 추천 목록에 더 많이 포함된 것을 확인할 수 있었다. 이렇듯 제안모델의 경우, 가구당 TV 시청 사용자가 여러 명이더라도 시청 시간대에 따른 다양한 콘텐츠들을 제공함으로써 보다 정확한 추천을 제공할 수 있다.

제안 모델과 다른 모델과의 추천 목록 비교를 위해 동일한 입력 시퀀스로 추론을 수행, 추천 목록을 생성한 결과는 표 7과 같다. 표 7에서와 같이 제안 모델에서 생성한 추천 목록의 경우, 시청 콘텐츠 시퀀스만을 고려한 경우에 비해 예능 콘텐츠들이 추천 목록의 상위에 더 많이 포함되어 있음을 확인할 수 있었으며, 그림 5에서와 같이 주말 새벽에 특히 더 시청되는 시사교양 콘텐츠도 함께 포함되어 있음을 확인할 수 있었다. 또한 **ground truth** 값인 ‘Kang’s Kitchen 2(신서유기 외전 강식당 2)’의 추천 순위 값이 제안 모델의 경우 1위, 비교모델3의 경우 3위로 차이를 보여 **average precision** 값도 제안모델이 더 높은 값을 나타냈다.

V. 결 론

본 논문에서는 콘텐츠 시청이력 뿐만 아니라, 콘텐츠를 시청한 시간대 및 콘텐츠 장르 정보를 활용하여 IPTV 시청 환경에 적합한 모델을 제안하였다. IPTV 시청의 경우, 특정 사용자에게 식별하기가 어려움이 있기 때문에 이러한 제약을 극복하기 위해 사용자와 시청 시간대를 함께 고려하여 추천을 제공하도록 하였다. 제안 모델의 성능 검증

을 위해 기존 LSTM 모델과 성능 비교실험을 수행하였고, 실험 결과, 제안 모델의 추천 정확도 **mAP**가 기존 LSTM 모델에 비해 향상되었음을 확인하였다. 또한 정성적으로도 제안 모델의 추천 결과가 기존 모델과 달리 시청 시간대에 따라 의미 있게 달라지는 것을 보임으로써 제안 모델의 차별성을 보였다. 향후 계획으로는 시청 시간대와 더불어 부가적인 다양한 상황정보, 콘텐츠 내용정보 등을 활용하여 만족도 높은 콘텐츠 추천 모델을 설계할 계획이다.

참 고 문 헌 (References)

- [1] S. Hochreiter, and J. Schmidhuber, "Long shortterm memory, Neural Computation," Vol. 9, No. 8, pp. 1735-1780, 1997.
- [2] H. Bang, H. Lee, and J. Lee, "TV Program Recommender System Using Viewing Time Patterns," Journal of Korean Institute of Intelligent Systems, Vol. 25, No. 5, pp. 431-436, Oct. 2015.
- [3] H. Chang and C. Chung, "TV Show Recommendation considering the Distinctive Features of TV Show Contents," Proceeding of conference of Korean Institute of Information Scientists and Engineers, Vol. 39, No. 2(B) pp.162-164, Nov.. 2012
- [4] E. Kim and M. Kim, "Topic-tracking-based dynamic user modeling with TV recommendation applications, " Applied Intelligence, Vol 44 Issue 4, pp. 771-792, June 2016
- [5] S Zhang, L. Yao, A. Sun and Y. Tay, "Deep learning based recommender system a survey and new perspectives," arXiv:1707.07435, 2016
- [6] Bing Bai, Yushun Fan, Wei Tan, and Jia Zhang, DLTSR: A Deep Learning Framework for Recommendation of Long-tail Web Services. IEEE Transactions on Services Computing, PP(99), 1-1, 2017.
- [7] T. Donkers, B. Loepp, and J Ziegler. "Sequential user-based recurrent neural network recommendations," In Recsys. pp. 152 - 160, 2017
- [8] Paul Covington, Jay Adams, and Emre Sargin, "Deep neural networks for youtube recommendations," In Recsys, pp.191 - 198, 2016
- [9] B. Hidasi, A. Karatzoglou, L. Baltrunas and D. Tikk, "Session-based Recommendations with Recurrent Neural Networks," arXiv:1511.06939, 2016
- [10] J. Chung, C. Gulcehre, K. Cho, Y. Bengio, "Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling," CoRR, abs/1412.3555, 2014
- [11] R. Devooght, and H. Bersini, "Collaborative filtering with recurrent neural networks," arXiv preprint, arXiv:1608.07400, 2016.
- [12] T. Mikolov, K. Chen, G. Corrado and J. Dean, "Efficient Estimation of Word Representations in Vector Space," arXiv:1301.3781,2013

저 자 소 개

표 신 지



- 2016년 8월 : 한국과학기술원 정보통신공학 박사
- 2018년 3월 ~ 현재 : SK텔레콤 ICT기술센터
- ORCID : <https://orcid.org/0000-0003-2702-905X>
- 주관심분야 : 콘텐츠 추천, 개인화, 딥러닝

정 진 환



- 2005년 2월 : 고려대학교 컴퓨터학과 박사
- 2005년 ~ 2014년 : 한국전자통신연구원
- 2014년 ~ 현재 : SK텔레콤 ICT기술센터
- ORCID : <https://orcid.org/0000-0002-0996-4290>
- 주관심분야 : 추천, 미디어, 클라우드

송 인 준



- 2005년 2월 : 고려대학교 컴퓨터학과 석사
- 2018년 ~ 현재 : SK텔레콤 ICT기술센터
- ORCID : <https://orcid.org/0000-0001-8860-1211>
- 주관심분야 : 추천, 미디어, 분산시스템